

大模型迁移到 RWKV 范式迁移、成本模型与服务经济性

不是一次 POC，而是从 Transformer 注意力/KV-cache 范式迁移到 recurrent state / high-concurrency serving 范式。

rwkv.cn

新一代大模型架构
attention-free / 无 KV
cache
constant speed /
memory

PARADIGM

RADLADS

主迁移路线
白盒 full-size 架构替换

案例锚点 A
低风险验证
已优化 KV / 长上下文模型

案例锚点 B
高收益验证
高 KV 压力 / 高服务成本模型

2x-6x
高并发潜在降本
取决于 KV 压力与批占用率

结论先行：RWKV 迁移是一套面向 open-weight 大模型的通用架构迁移方案

问题	建议	原因	置信度
主方法	RADLADS full-size 白盒转换	保留 tokenizer、MLP/MoE、专家知识路径，只替换序列混合器	中
案例锚点 A	KV 已优化、active compute 较小的长上下文模型	适合验证架构映射、训练稳定性与 serving kernel，不代表唯一优先级	中
案例锚点 B	KV/cache 压力更高或服务成本更高的模型	适合验证商业降本上限；需要在方法稳定后放大	中低
旗舰案例	超大规模、高质量、长上下文模型	适合作为联合方案成熟后的旗舰验证，不建议作为首个样例	低
GAD 角色	后对齐或小模型学生	补 instruction/coding-agent 风格，不等于架构迁移	中

一句话判断

RADLADS 提供 full-size 架构迁移路径；GAD/SFT 用于迁移后的行为对齐与合作方场景适配。

对外口径

GLM 与 DeepSeek 只是公开案例锚点；真实合作目标应按模型开放性、KV/cache 压力、服务负载和质量门槛选择。

来源: RADLADS[4], GAD[5], 公开模型卡与服务价格文档。

rwkv.cn 给出的定位是架构范式，而不是实验性替代件



官网主张

rwkv.cn 使用“新一代大模型架构”“超越 Transformer”“无需 KV Cache”“超高并发”等表述。

工程含义

迁移收益来自服务形态变化，不来自把 754B/1.6T 压缩成小模型。

表达力含义

RWKV-7 的动态状态演化为“更强表达”提供理论支撑，需按任务验证。

RWKV 增长路径：从架构论文到引擎与迁移生态



架构线

从 RWKV 到 Eagle/Finch 再到 RWKV-7，核心是状态表达、动态递归和高效序列建模。

迁移线

RADLADS 与 OpenMOSE 让“把已有 Transformer/MoE 迁到 RWKV”变成可操作项目。

服务线

Albatross / high-concurrency 工程把无 KV cache 的理论优势转成吞吐与显存优势。

“RWKV 更有表达力”应落到 RWKV-7 的动态状态演化，而不是泛化成所有指标全胜

固定深度 Transformer

有限层 attention
适合并行匹配，但在某些状态跟踪、形式语言与递归更新任务上存在理论限制。

RWKV-7 动态状态

输入相关的状态转移矩阵让每一步都能更新内部记忆，形成可迭代的 recurrent computation。

范式判断

论文支持的是“状态表达能力”强于固定深度 Transformer 的若干理论场景；生产质量仍需 benchmark 验证。

PPT 表述建议

可以说: RWKV-7 从形式语言/状态跟踪角度给出比固定深度 Transformer 更强的表达力论证。

不要过度承诺

不要说: RWKV 在所有任务上天然超过 Transformer。迁移后的 GLM/DeepSeek 仍要通过质量、长上下文和工具调用评测。

依据: RWKV-7 “Goose” with Expressive Dynamic State Evolution [3].

RADLADS 是 full-size 架构迁移；GAD 是行为蒸馏，适合作为后对齐

方法	做什么	需权重	full-size 转换	最佳用途	主要风险
RADLADS	替换 attention 为 RWKV/linear mixer，隐藏状态 + logits 对齐	是	是	迁移 open-weight Transformer/MoE	内存、映射、长上下文退化
GAD	黑盒 on-policy 生成 + 判别器/奖励蒸馏	否	否	后对齐、API 教师、小 RWKV 学生	行为像但内部知识不保真
SFT / SeqKD	监督学习教师输出	否	否	格式、风格、廉价 warmup	复制表面模式，弱于策略/工具行为

为什么先 RADLADS

案例锚点 B 和 DeepSeek V4 是 open-weight，能访问权重、hidden states 和 logits。

为什么还要 GAD

转换后仍可能丢失 instruction、coding-agent、工具调用风格；GAD 用来补行为层。

关键边界

GAD 可以训练 7B/14B/30B RWKV，但这不是 full-size 范式迁移。

full-size RWKV

迁移不会显著缩小模型，收益来自服务状态与调度

目标	原始规模	预期 RWKV 规模	规模差异	真正变化
OpenMOSE GLM-4.7 例子	31.221B	30.315B	-2.9% 实测	attention -> RWKV-7/TICA
案例锚点 B	753.864B	~730B-760B	通常 +/-5%	DSA/attention -> RWKV mixer
DeepSeek V4 Flash	284B/292B	~280B-295B	通常 +/-5%	CSA/HCA -> RWKV mixer
DeepSeek V4 Pro (旗舰案例)	1.6008T	~1.55T-1.62T	通常 +/-5%	旗舰 full-size 项目

经济逻辑

不是把 754B 或 1.6T
压成小模型，而是让长上下文服务不再按每个请求累积巨大 KV cache。

研发逻辑

保留 MoE/MLP/embedding/ tokenizer，降低从零预训练 RWKV 的成本与知识损失。

来源: OpenMOSE model card 与前序 safetensors 参数统计。

模型清单用于说明选型方法：不同大模型对应不同迁移收益与工程风险

模型	开放状态	HF/card 规模	active	上下文	架构事实	RADLADS 可行性
OpenMOSE RWKV-GLM-4.7	open	30.315B	A3B	202K	47 层 RWKV-7, 20 层 TICA	已是 alpha 参考
案例锚点 B: GLM-5.1	open / MIT	753.864B	未明示	200K	78 层, hidden 6144, 256 experts, top-8	高收益但高风险
案例锚点 A: DeepSeek V4 Flash Base	open / MIT	292B/card 284B	13B	1M	43 层, hidden 4096, 256 experts, top-6	低风险案例锚点
旗舰案例: DeepSeek V4 Pro Base	open / MIT	1.6008T/card 1.6T	49B	1M	61 层, hidden 7168, 384 experts, top-6	旗舰案例锚点

合作评估起点

先用可复现实验建立共同评测口径：同 prompt、同 tokenizer、同解码，测质量、长上下文、VRAM 与吞吐。

低风险样例

较小 active compute
与长上下文模型适合做低风险样例，用来验证迁移链路和服务收益。

高收益样例

服务成本更高或 KV/cache
压力更高的模型，适合在方法稳定后验证更大的商业降本空间。

RADLADS 的核心是先替换注意力，再用 hidden states 与 logits 拉回教师行为



为什么比从零预训练便宜

序列混合器只需要学习模拟原 attention 输出和最终 logits，知识主要留在原 MLP/MoE 路径。

为什么仍然难

GLM/DeepSeek 是 MoE 和长上下文模型，路由、归一化、位置编码、teacher-student 显存都可能成为失败点。

转换预算的主风险不是单次 GPU-hour，而是失败重跑与长上下文调试

目标	硬件假设	墙钟	GPU-hours	compute-only	项目预算
DeepSeek V4 Flash -> RWKV	32-64 H100	2-5 天	1,536-7,680	\$6K-\$47K	\$50K-\$150K
案例锚点 B -> RWKV	128-256 H100	4-10 天	12,288-61,440	\$49K-\$378K	\$250K-\$1M
DeepSeek V4 Pro (旗舰案例) -> RWKV	256-512 H100	7-21 天	43,008-258,048	\$172K-\$1.59M	\$1M-\$4M

估算基础

RADLADS 发布了 7B/32B/72B dense 转换锚点；这里按 MoE 规模、双模型显存和重跑风险放大。

为何区间宽

公开结果不是 284B/754B/1.6T MoE；真实成本由架构映射、路由和长上下文稳定性决定。

预算口径

compute-only
不含工程、评测、数据、失败 run 和 serving kernel 开发。

H100 价格使用 \$3.99-\$6.16/GPU-hour planning range。

已有 KV 压缩的大模型仍可迁移；收益应按高并发与长会话重算

项目	已有 KV 压缩模型	RWKV 迁移后	解释
单请求短上下文	KV 压力已低	收益有限	active compute、权重加载与 MoE 路由仍占主导
1M 长上下文	KV 约为常规 GQA-8 基线的很小比例	状态近似固定	已有 KV 压缩降低了传统 Transformer 的一部分弱点
500+ 并发长会话	小 KV 也会乘以用户数	状态随并发线性但不随上下文膨胀	这是该类模型仍可通过 RWKV 获得高并发收益的主要来源



结论

对已优化 KV 的模型，RWKV 不是简单 10x 叙事；合理目标是高并发长会话的 2x-4x 级收益。


对比

对 KV/cache 压力更高的模型，RWKV 降本空间可能更接近 3x-6x。

依据: 公开技术报告/模型卡；本页为工程推导而非官方报价。

RWKV 的服务优势不是单流速度，而是高 batch 下的总 decode 吞吐

模型	精度	Batch	总速度	阶段	硬件	相对 batch1
RWKV-7 7.2B	fp16	1	145+ tok/s	Decode	RTX5090 单卡	1x
RWKV-7 7.2B	fp16	320	9650+ tok/s	Decode	RTX5090 单卡	~66.6x
RWKV-7 7.2B	fp16	960	10250+ tok/s	Decode	RTX5090 单卡	~70.7x
RWKV-7 7.2B	fp16	1	11289+ tok/s	Prefill	RTX5090 单卡	N/A



使用边界

机制证据，不做 7.2B 到 284B/754B 的线性外推；真实收益要在目标 MoE 上实测。

高并发不仅靠 batch: DPLR 让 RWKV-7 沿时间维度做 chunk 并行

顺序递推

逐 token 更新状态:
 $S_t = P_t S_{t-1} + k_t^T v_t$

低延迟 decode 仍顺序; 训练/长 prefill 会受时间依赖限制。

DPLR 显式转移

$$P_t = \text{diag}(\exp(g_t)) + b_t a_t^T$$

对角衰减控制 dim-wise forgetting, 低秩项提供跨维耦合。

Chunk-wise affine

一个 chunk 可压缩成:
 $S' = M S + B$

多个 chunk 的 (M,B) 可做 prefix scan / CP 并行。

为什么重要

把长序列计算从逐步串行, 改为 chunk 内局部计算 + chunk 间 affine scan, 是训练/预填充的第二条高并发路线。

代价

引入中间变量和 HBM 压力; 主要用于训练与长 prefill 并行, 不直接等同于交互式 decode 加速。

放进成本模型

评估需拆成 decode 高 batch、prefill 时间并行、长会话 state/KV memory 三项收益。

新增引用 [9]: Zhiyuan Li, DPLR 数学原理: 显式转移矩阵的并行计算, 2026-02-21, zhiyuan1i.github.io/posts/dplr-mathematics/

高并发把 KV cache 从单请求问题放大成集群 sizing 问题

负载形态	低 KV 案例 -> RWKV	旗舰案例 -> RWKV	高 KV 压力案例 -> RWKV	原因
短聊天 / <8K / 低并发	5%–15%	5%–15%	10%–20%	KV 压力不足，active compute 主导
普通 coding / 8K–32K	10%–25%	10%–25%	20%–40%	有 batching 与少量 cache 收益
Agent 服务 / 32K–128K	30%–55%	25%–50%	45%–70%	并发会话开始放大状态成本
多 agent fan-out	40%–70%	35%–65%	55%–80%	接近 RWKV 高 batch 优势场景
长驻高并发长上下文	50%–75%	45%–70%	65%–85%	KV/cache 乘以会话数

低 KV 案例

已有小 KV 时，合理目标不是 10x，而是高并发 2x–4x。

高 KV 压力案例

KV 压力更高时，高并发长上下文可能达到 3x-6x。

如果能保持质量并跑满高并发，RWKV 自托管可把 API 等效价拉到明显更低

模型	当前公开 API 价	低/中并发 RWKV 目标	高并发 RWKV 目标	备注
DeepSeek V4 Flash	\$0.14 in / \$0.28 out	\$0.10–\$0.13 / \$0.20–\$0.26	\$0.04–\$0.10 / \$0.06–\$0.16	cache-hit input 极难打
DeepSeek V4 Pro（旗舰案例）折扣	\$0.435 / \$0.87	\$0.35–\$0.43 / \$0.65–\$0.85	\$0.15–\$0.35 / \$0.25–\$0.55	需高利用率
DeepSeek V4 Pro（旗舰案例）标价	\$1.74 / \$3.48	\$1.20–\$1.60 / \$2.40–\$3.20	\$0.40–\$1.00 / \$0.60–\$1.50	可打标价
案例锚点 B	\$1.40 / \$4.40	\$0.80–\$1.10 / \$2.20–\$3.30	\$0.20–\$0.70 / \$0.60–\$1.80	经济 upside 最大

成本公式

self-hosted \$/MTok = GPU-hour price / (aggregate tok/s * 3600 / 1M) + overhead。

重要前提

上表不是 provider quote；它假设模型质量接近教师、serving stack 能保持高 batch occupancy。

单位: USD per million tokens, input/output。价格随厂商和折扣变化，需要上线前重查。

候选模型选择取决于工程风险、经济 upside 与合作目标

目标	优点	缺点 / 风险	最佳角色
案例 A：低风险长上下文模型	active compute 较小、已有 KV 优化、开放权重；适合验证迁移链路	需证明 RWKV 在强 KV baseline 上仍有高并发收益	低风险案例锚点
案例 B：高收益成本模型	服务成本高、长上下文/KV 压力更明显；适合验证商业降本上限	总参数和 MoE 复杂度更高；需要更强 infra 与评测投入	高收益案例锚点
旗舰案例：超大规模模型	最高质量或最长上下文目标；适合成熟路线后的联合验证	teacher+student 显存、存储和失败成本极高	旗舰合作项目

低风险案例

此类模型适合先验证架构映射、训练稳定性和 serving kernel，而不是承诺最大降本。

高收益案例

此类模型适合在迁移链路稳定后验证更大的商业降本空间。

旗舰案例

旗舰级模型适合在方案成熟后作为联合验证项目，不建议作为首个合作试点。

迁移是否成功，不能只看 loss；必须同时过质量、长上下文和服务门槛

Gate	通过标准	失败信号	处理
质量保真	核心 eval >=90%–95% teacher	知识、推理、代码显著掉点	回看 KL/hidden 目标与数据
长上下文	32K/128K/200K/1M 按目标稳定	NIAH/RULER 掉到不可用	长上下文 KL/CE 与状态设计
服务收益	高 batch aggregate tok/s 与 VRAM 明显优于 teacher	单流可用但 batch 不放大	kernel/scheduler 重写
工具/agent	tool-call、repo-agent、SWE slice 不退化	格式漂移、长链路崩	GAD/SFT 后对齐
可运营性	checkpoint、quant、监控、回滚可行	只在研究脚本可跑	先服务 Flash，不先上 Pro

最低上线门槛

至少同时证明质量接近、长上下文有效、高并发成本下降。缺一项都只能算研究样机。

范式迁移门槛

能在同一 serving stack 中把 KV-cache fleet pressure 改成 recurrent-state fleet pressure。

合作路线图：先建立共同评测口径，再选择合适案例进入 full-size 迁移



阶段退出条件

若基准样例未达到 90%-95% 质量或长上下文不可用，应先修正方法再放大。

合作试点建议

合作试点应选择真实高并发 agent/coding 或长上下文负载，用实际 batch occupancy 测成本。

参考资料编号：本 deck 说明通用迁移方案，并以公开模型与公开资料作为案例锚点

编号	资料	用途	[9] DPLR 时间维度并行：显式转移矩阵、chunk-wise affine 与 prefix-scan 并行。
[0]	rwkv.cn	官方定位: 新一代架构、无 KV cache、高并发	https://www.rwkv.cn/
[1]	RWKV: Reinventing RNNs for the Transformer Era	RWKV 基础架构论文	arXiv:2305.13048
[2]	Eagle and Finch: RWKV with Matrix-Valued States and Dynamic Recurrence	矩阵状态与动态递归	arXiv:2404.05892
[3]	RWKV-7 “Goose” with Expressive Dynamic State Evolution	表达力与动态状态演化论证	arXiv:2503.14456
[4]	RADLADS: Rapid Attention Distillation to Linear Attention Decoders at Scale	full-size 转换方法	arXiv:2505.03005
[5]	GAD: Generalized Autoregressive Distillation	后对齐/小模型行为蒸馏	arXiv:2511.10643
[6]	OpenMOSE RWKV-GLM-4.7-Flash-exp	30B 级 full-size RWKV 参考	Hugging Face
[7]	公开模型卡与技术报告	规模、上下文、KV/cache 与价格假设	HF / docs
[8]	RWKV 超并发项目教程	RTX5090 batch 1/320/960 实测锚点	mp.weixin 本地 HTML

对外合作建议

将 RWKV 迁移作为“架构范式迁移 + 服务经济性验证”的联合方案推进；GLM/DeepSeek 仅作为公开案例锚点，具体模型按合作目标选择。

注: 具体 API 价格、模型卡参数与论文版本会更新；正式投资/上线前需要再次核验。